



Strompreis-Vorhersage Deutschland

Folgeprojekt von Stromverbrauch-Vorhersage

Machine Learning für stündliche Strompreis-Prognosen · Wetter · Kalender · SMARD

SMARD API

Marktdaten

MaStR

PV- u. Windanlagendaten

OPEN-METEO


Wetterdaten

Streamlit App

Output

Projektziel: belastbare 24h-Preisprognose

Ziel ist eine Prognose, die im Tagesbetrieb interpretierbar und mit offiziellen Marktdaten vergleichbar ist.



Rekursive Machine Learning Ablauf

- Historische Vorhersage nutzt die historische Daten aus SMARD
- Vorhersage für morgen setzt auf die Vorhersage der Stromverbrauch, PV und Wind Energie-Erzeugung und die Wettervorhersage als Rohdaten
- Durch die Visualisierung werden signifikante Abweichungen entdeckt. Daraufhin werden neue Features dafür gebildet und die Modelle neu trainiert.

Datenbasis: historische Last + Wetter + Kalender

Die Prognose kombiniert langfristige Verbrauchsmuster mit kurzfristigen Wetter- und Kalendereffekten.



MaStR

Stromerzeuger bis Mai 2026
Cluster aus Koordinaten und
Leistungen als Gewichte

Open-Meteo

Historische Wetterdaten
nach Erzeuger-Cluster gewichtet

Gestapelte Vorhersage



Vorhersage für morgen hänge von
Stromerzeugungs- und
Stromverbrauchsvorhersage ab

SMARD + OPEN-METEO API

Historische Daten
offizielle Vorhersage + Prognose

	MaStrR	SMARD	OPEN-METEO
Daten	MaStrR - Marktstammdatenregister	Netzlast-Marktdaten	Wetterdaten
Source	marktstammdatenregister.de	Bundesnetzagentur SMARD.de	Open-Meteo open-meteo.com
Lizenz	DL-DE->BY-2.0	CC BY 4.0	CC BY 4.0



EDA: Saison, Trend und zeitliche Verteilung und Effekte



Erkenntnisse

- Analog zu dem Stromverbrauch haben die Strompreise auch deutliche Stunden-, Wochentages-, Monats-Saisonalität.
- Der Strompreis ist gegenüber dem Stromverbrauch tendenziell leicht steigend.



EDA: Ausreißeranalyse



Erkenntnisse

- Mit empirischem und RANSAC Regression (basiert auf konventioneller Stromerzeugung) werden Ausreißer identifiziert
- Extreme hohe Preise: Energiekrise August 2022, Ende 2025 - gestiegene Netzentgelte, hohe Beschaffungskosten an den Energiebörsen, Ende der Subvention
- Negative Preise: saisonal (früh Sommer) niedriger Verbrauch, zunehmende PV Anlage, mangelnde Stromspeicherkapazität

Aggregation der Wetterdaten



Berechnung der Wetterdaten:


- Die PV und Wind (Offshore + Onshore) Anlagen Daten mit Nettoleistung und Betriebsnahmendatüme aus MaStrR
- Mit KMeans jeweils 10 Cluster gebildet. Die Koordinaten der Centroids für Wetterdatenabfrage verwendet
- Die Wetterdaten (Windgeschwindigkeit auf 100 Meterhöhe, Sonnenstrahlung, Wolkendeckung) aus open-meteo
- Wetterdaten mit jeweiliger jährlichen Kapazitäten gewichtet

Erkenntnisse

- PV Anlagen liegen vorwiegend im Osten des Landes. Norden und Süden sind relativ ausgeglichen
- Wind-Erzeugung stammt in erster Linie aus dem Norden. Die Offshore Windanlage haben die größten Kapazitäten.

Feature Engineering – Kombination aus verschiedenen Quellen

Die (58) Features aus historischen Markt-, Wetterdaten, Wettervorhersagen und Feature Engineering





Eventuelle Erweiterungen:
Konventionelle Erzeugung, Feiertagenname

Modellvergleich: XGBoost/LightGBM liegen nahe beieinander

Modell	MAE	RMSE	R ²	Trainingsdauer (Bayesian Optimization)
XGBoos	14.48	23.46	0.79	~10'13"
LightGBM	14.71	23.74	0.79	~1'25"

Lernkurven:

- Validierungsfehler sinkt mit mehr Daten, stagniert bei 13000 Datenpunkt.
- Der Lücke zum Trainingsfehler bleibt aber sichtbar.




Erkenntnisse

- XGBoost liefert die beste MAE, LightGBM ist fast gleich gut, aber schneller.

Feature Importances

Permutation Feature Importance (MAE) - Top 15 Features




Erkenntnisse

- LightGBM und XGBoost verweisen die Wichtigkeit auf unterschiedlichen Features
- Preise in der Vergangenheit, Residuallast, Winderzeugung und Wetter-Winddaten spielen die größten Rolle
- Vermutlich die PV Erzeugung durch Residuallast repräsentiert.

Hinweis

Feature Importance nicht als Kausalität interpretieren

Tagesprognose für morgen - Vergleich mit 7 Tage Mittel und Residuallast



Anwendungshinweise

- Tagesprognose Vergleich mit dem Durchschnitt der letzten 7 Tage und der Residuallast für die Interpretierbarkeit
- Modellauswahl
 - LightGBM
 - XGBoost
- Vorhersage von verschiedenen Modelle sind unterschiedlich

7 Tage

Realpreis

Residuallast

Prognose


ML morgen

Prognose

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster. ML Vorhersage hat stärkere Schwankungen als die realen Preise.

Historischer Vergleich Vorhersage vs Reale Preise



Vorhersage Vergleich

- Zeitraum ausgewählt mit Ausreißer in der Vergangenheit
- Große Abweichung an einzelnen Tagen
- Vergleich mit
- Neue Features kreieren

MAE	RMSE	R ²	Datenpunkte
19.44 €/MWh	32.04 €/MWh	0.766	1,032

MAE

Primäre Metrik

RMSE

Sekundäre Metrik

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster. SMARD Prognose ist eher konservativ mit weniger Unterschätzungen.

Fazit und Folgeprojekt

Projektfazit

- Aggregation der Wetterdaten anhand der Erzeuger und deren Kapazitäten führt zu genauer Vorhersage der Energie-Erzeugung
- Datenlücke erzwingt die Preise mit Erzeugung- und Verbrauchsvorhersage zu prognostizieren
- Die Features für Zeit, Wetter, Erzeugung und historische Preise bzw. die Lag und Rolling Features fließen als Prädiktoren ein
- Feature Engineering (Kombinationen) führt zu leicht Verbesserung

Verbesserungspotential

- Automatisches Modelltraining mit neu gewonnenen Daten
- Weitere Daten aus SMARD abrufen als Features
- Weitere Features mit Zeit und Erzeugung, Wetter, Preise kombinieren
- Weitere Modelle – Ensemble, ANN probieren

To be continued: **Ausfallvorhersage - Predictive Maintenance**
NASA Turbine