


Stromverbrauch-Vorhersage Deutschland



Machine Learning für stündliche Netzlast-Prognosen · Wetter · Kalender · SMARD-Vergleich

2019–24 / 2025

Train/Test Split

SMARD API


Aktualisierung

Streamlit App

Output

Projektziel: belastbare 24h-Lastprognose

Ziel ist nicht nur ein hoher R^2 -Wert, sondern eine Prognose, die im Tagesbetrieb interpretierbar und mit offiziellen SMARD-Werten vergleichbar ist.




Rekursive ML Ablauf

- Von Problem → Daten → Features → Modell → Anwendung
- Feature Engineering trägt mehr zu der Vorhersage bei als die Modellselektion und -tuning
- Feature Selektion nach Feature Importance Analysis
- Parameter Tuning und Interaktive GUI → Überarbeitung der Funktionalität
- Verschiedenen Zeitformate verursacht Synchronisationsprobleme
- ETL Pipeline verbessert Reaktionszeit, Datensicherheit und -konsistenz

Datenbasis: historische Last + Wetter + Kalender

Die Prognose kombiniert langfristige Verbrauchsmuster mit kurzfristigen Wetter- und Kalendereffekten.



Kaggle

Stündliche Lastdaten
CountryCode = DE

Open-Meteo

Historisches Wetter
Top-5-Städte nach Population
gewichtet

python-holidays

Feiertage, Brückentage,
Bundesland-Anteil


SMARD API

Aktuelle Netzlast +
offizielle Prognose

Datenlizenzen:

ENTSO-E, CC BY-SA 4.0






EDA: Saison, Trend und zeitliche Verteilung und Effekte



Erkenntnisse

- Der Stromverbrauch hat deutliche Stunden-, Wochentages-, Monats-Saisonalität.
- Der Stromverbrauch ist an arbeitsfreien Tage deutlich niedriger als sonst.
- Langzeit-Trend ist in langen Zyklen enthalten. Für Langzeitprognose muss diese berücksichtigt werden.

EDA: Wettereinfluss auf Stromverbrauch



Erkenntnisse

- Der Stromverbrauch hat Zusammenhang mit der Temperatur, Sonnenstrahlung und Windgeschwindigkeit.
- Der Niederschlag spielt eher eine kleine Rolle und fügt womöglich Rauschen in das Modell ein

Feature Engineering: starke Signale statt Modellkomplexität

Die größte Qualitätssteigerung entsteht durch saubere Zeitreihenfeatures und Lecksichere Rolling-Werte.

Zeit & Kalender

- hour, weekday, month
- is_weekend, is_workday
- is_holiday, is_bridge_day
holiday_ratio, holiday_weight
- is_pandemic_time

Wetter

- apparent_temperature
- rain / snowfall
- wind_speed_10m
- shortwave_radiation
- heating/cooling_degree

Historie

- lag_24h, lag_168h
- rolling_mean_24h
- rolling_mean_168h
- shift(1) gegen Leakage
- **wichtigste Features**

Eventuelle Erweiterungen:



Feiertagsnamen, Schulferienratio, Abstände zu Feiertage und ggf. Industrieproduktionsindex (für Langzeitprognose)

Modellvergleich: XGBoost/LightGBM liegen nahe beieinander

Modell	MAE	RMSE	R ²	Dauer
XGBoost	1156.96	1500.81	0.97	10'55"
LightGBM	1219.06	1604.48	0.97	2'30"

Lernkurven:


- Validierungsfehler sinkt mit mehr Daten, stagniert bei 13000 Datenpunkt.
- Der Lücke zum Trainingsfehler bleibt aber sichtbar.



Erkenntnisse

- Beide Modelle profitieren stark von Lag-/Rolling-Features.
- XGBoost liefert die beste MAE, LightGBM ist fast gleich gut und schneller.

Feature Importances: Vorwoche schlägt Wetter




Erkenntnisse

- Verbrauch der Vorwoche ('lag_168h') ist der stärkste Saisonalitätsanker
- Tageswerte ('lag_24h') und Rolling Means stabilisieren kurzfristige Schwankungen
- Wetterfeatures liefern Zusatzsignal, aber erklären nicht alles.

Hinweis

Feature Importance nicht als Kausalität interpretieren

Tagesprognose für morgen: Streamlit/Interactive Notebook



Nutzen der GUI

- Tagesprognose sofort sichtbar
- SMARD-Prognose als Referenz
- Tabellarische Werte für Export/Prüfung
- Modellauswahl
 - LightGBM
 - LightGBM_conservative
 - XGBoost
 - XGBoost_conservative


SMARD
Vergleichslinie

ML
Prognose

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster.

Historischer Vergleich: Real vs. SMARD vs. ML



Series	MAE (MWh)	RMSE (MWh)	Points
ML Prediction (LGBM)	1,407	1,762	456
SMARD official forecast	2,626	3,280	456

Nutzen der GUI

- Anfang und Ende der Zeit für die Vorhersage.
- Empfehlung: Feiertage und Ferienzeiten auswählen für die Sonderfällen
- Vergleich mit SMARD Prognose
- Modellauswahl
 - LightGBM
 - LightGBM_conservative
 - XGBoost
 - XGBoost_conservative

MAE

Primäre Metrik


RMSE

Nebenmetrik

Erkenntnis

Tagesvorhersage folgt dem täglichen Muster. SMARD Prognose ist höher als die Vorhersage, eher konservativ.

Konservative Vorhersage: mehr Puffer



Neues Modell:

- Mit asymmetrischer Verlust werden die Modelle trainiert
- Mit Parameter Alpha=0.95, 5% Unterschätzung
- Die Metriken werden dadurch verschlechtert
- Modelle:
 - LGBM_conservative
 - XGB_conservative

MAE

Primäre Metrik

RMSE

Nebenmetrik

Erkenntnis

Mit asymmetrischer Verlust weniger Unterschätzung für die Netzbetreiber. SMARD Prognose enthält vermutlich zusätzlich statisches Offset zu mehr Sicherheit

Fazit und Folgeprojekt

Projektfazit

- Das Portfolio-Projekt nutzt echte Daten, klare Pipeline, Modellvergleich und Demo-App.
- Lag-/Rolling-Features sind der zentrale Performance-Treiber.
- XGBoost/LightGBM sind derzeit die stärksten Kandidaten.
- Der SMARD-Vergleich macht das Ergebnis praxisnah.
- Die Diagnose in der Produktion ist eher konservativ
- Mit der Erweiterung der asymmetrischen Verlust ist die Vorhersage noch produktionsnah
- Automatische ETL Pipeline verbessert die App-Reaktion und die Datenkonsistenz

Nächste Schritte

- Feiertags-/Brückentagsfehler separat evaluieren und Feature-Set erweitern.
- Schulferienratio, Abstände (vor und nach) zu Feiertage hinzufügen
- Industrieproduktionsindex testen.

To be continued:

Vorhersage der Residuallast

$\text{Residuallast} = \text{Netzlasterzeugung} - \text{PV} - \text{Wind} - \text{konventionelle Erzeugung}$